Datenanalyse von Lieferverzögerungen in der Supply Chain

Einflussfaktoren. Vorhersage. Optimierungspotenzial

Agata Makrocka

Ziel der Analyse

- Identifikation von Faktoren, die Lieferverzögerungen beeinflussen
- Ableitung möglicher Optimierungsansätze

```
irrelevant_columns = [
    'Customer Email', 'Customer Fname', 'Customer Lname', 'Customer Pass
    'Customer Street', 'Customer Zipcode', 'Customer Id', 'Order Custome
    'Product Image', 'Product Status', 'Product Card Id',
    'Product Category Id', 'Category Id', 'Department Id'
]

# Drop the irrelevant columns
df_cleaned = df_cleaned.drop(columns=irrelevant_columns)

print("Shape of DataFrame after dropping irrelevant columns:", df_cleane
display(df_cleaned.head())
```

Shape of DataFrame after dropping irrelevant columns: (180508, 37)

	Type	Days for shipping (real)	Days for shipment (scheduled)	Benefit per order	Sales per customer	Delivery Status	Late_d
0	DEBIT	3	4	91.250000	314.640015	Advance shipping	
1	TRANSFER	5	4	-249.089996	311.359985	Late delivery	

Datenübersicht

Datensatz: DataCo Global (Kaggle)

Datenvorbereitung

- Bereinigung der Daten (fehlende Werte, Duplikate, auf Deutsch)
- Auswahl relevanter Spalten und Variablen

```
df_cleaned = df.copy()

# Drop columns that are entirely or mostly empty
df_cleaned = df_cleaned.drop(columns=['Product Description', 'Order Zipcode'])

# Drop rows with a few missing values in 'Customer Lname' or 'Customer Zipcode'
df_cleaned = df_cleaned.dropna(subset=['Customer Lname', 'Customer Zipcode'])

print("Shape of DataFrame after cleaning missing values:", df_cleaned.shape)
display(df_cleaned.isnull().sum())
```

Shape of DataFrame after cleaning missing values: (180508, 51)

	0
Type	0
Days for shipping (real)	0
Days for shipment (scheduled)	0
Benefit per order	0
Sales per customer	0
Delivery Status	0
Late_delivery_risk	0
Category Id	0
Category Name	0
Customer City	0
Customer Country	0

Zusatlich: Ubersetzung auf Deutsch

We will create a mapping dictionary for the most frequent categories and use the `.map()` function to create a new column `Category Name DE`.

```
category_translation = {
    'Cleats': 'Stollenschuhe',
    "Men's Footwear": 'Herrenschuhe',
    "Women's Apparel": 'Damenbekleidung',
    'Indoor/Outdoor Games': 'Indoor/Outdoor Spiele',
    'Fishing': 'Angeln',
    'Water Sports': 'Wassersport',
    'Camping & Hiking': 'Camping & Wandern',
    'Cardio Equipment': 'Cardio-Geräte',
    'Shop By Sport': 'Nach Sportart',
    'Electronics': 'Elektronik',
    'Accessories': 'Zubehör',
    'Golf Balls': 'Golfbälle',
    "Girls' Apparel": 'Mädchenbekleidung',
    'Golf Gloves': 'Golfhandschuhe',
    'Trade-In': 'Inzahlungnahme',
    'Video Games': 'Videospiele'
}

# Create a new column with German translations
```

Explorative Datenanalyse (EDA)
Analyse der Verkaufsgebiete
Meistverkaufte Produktkategorien

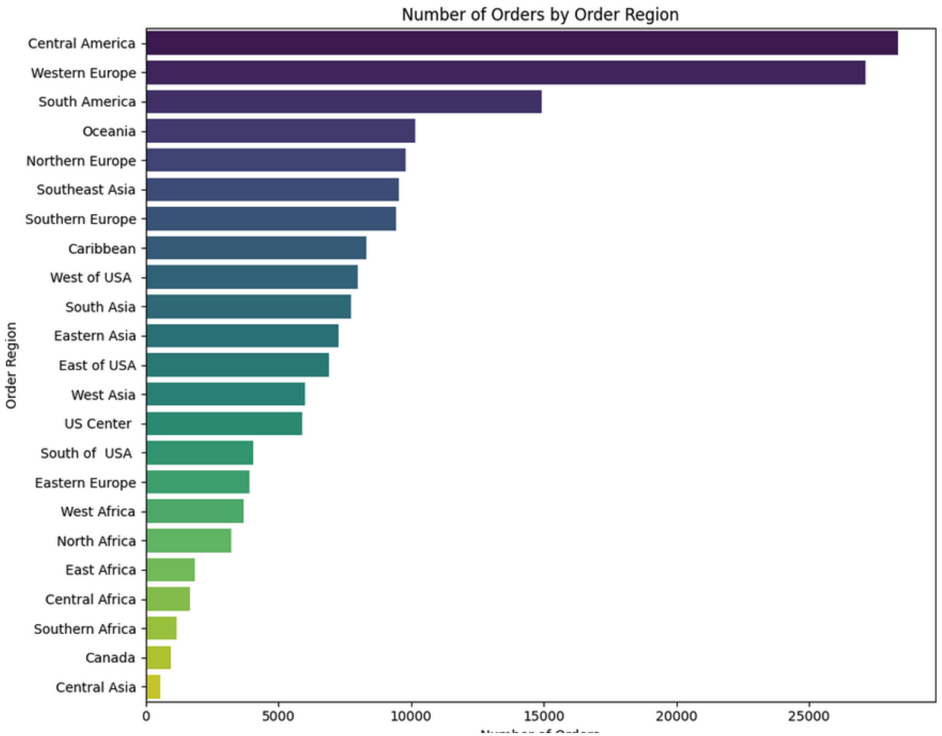

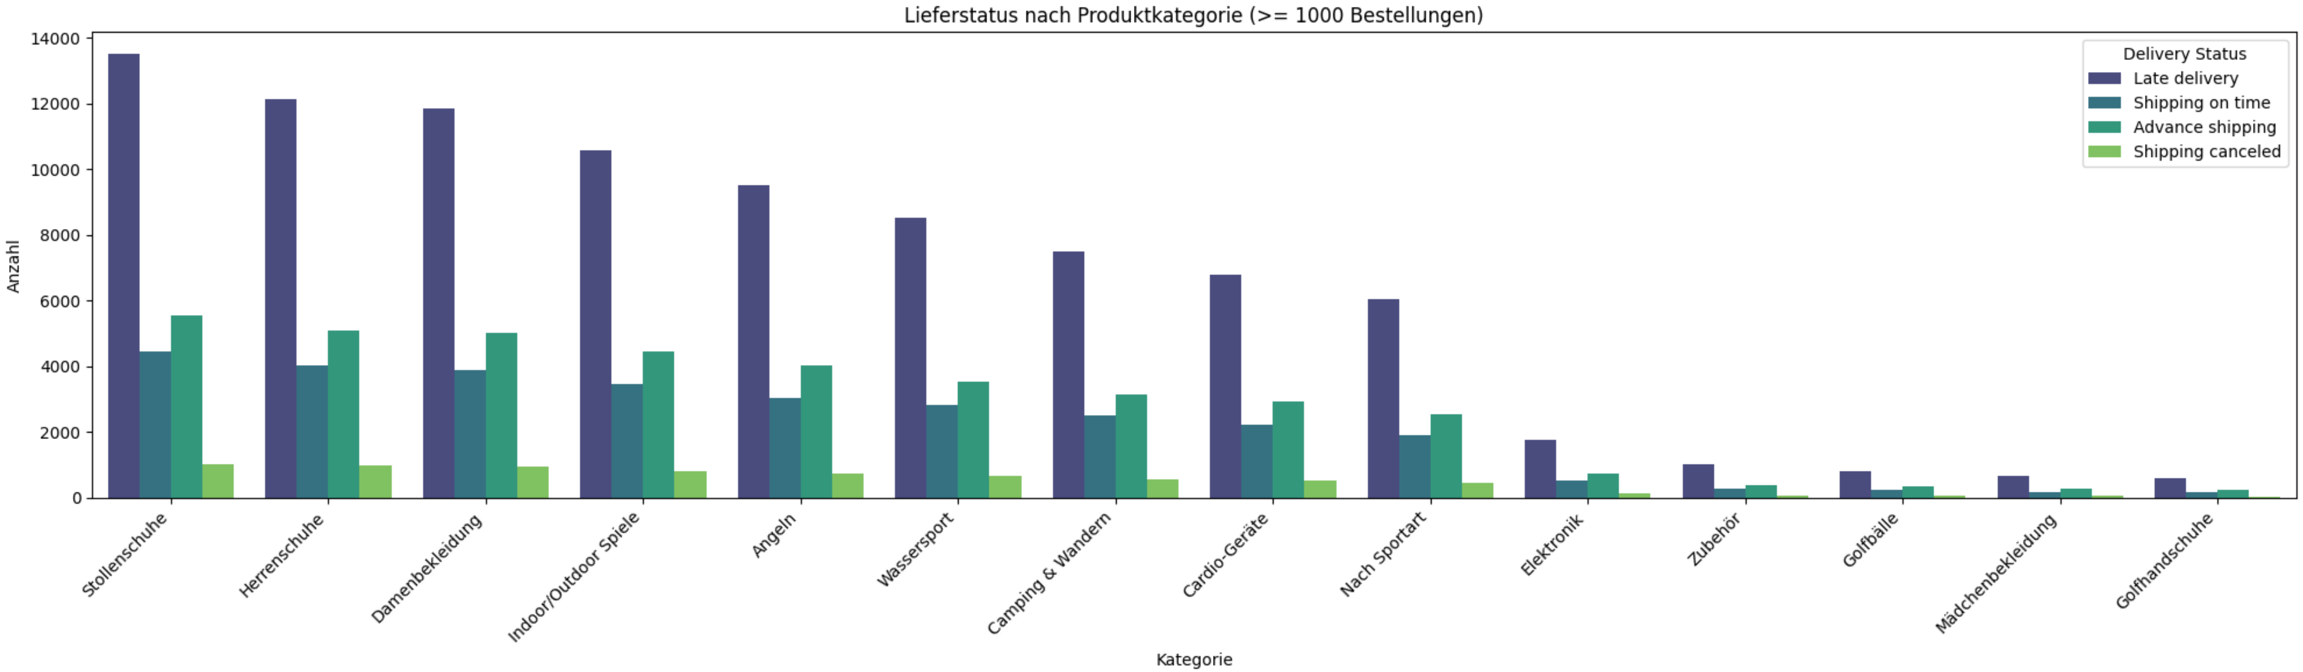

Explorative Datenanalyse (EDA)
Verteilung der Lieferoptionen

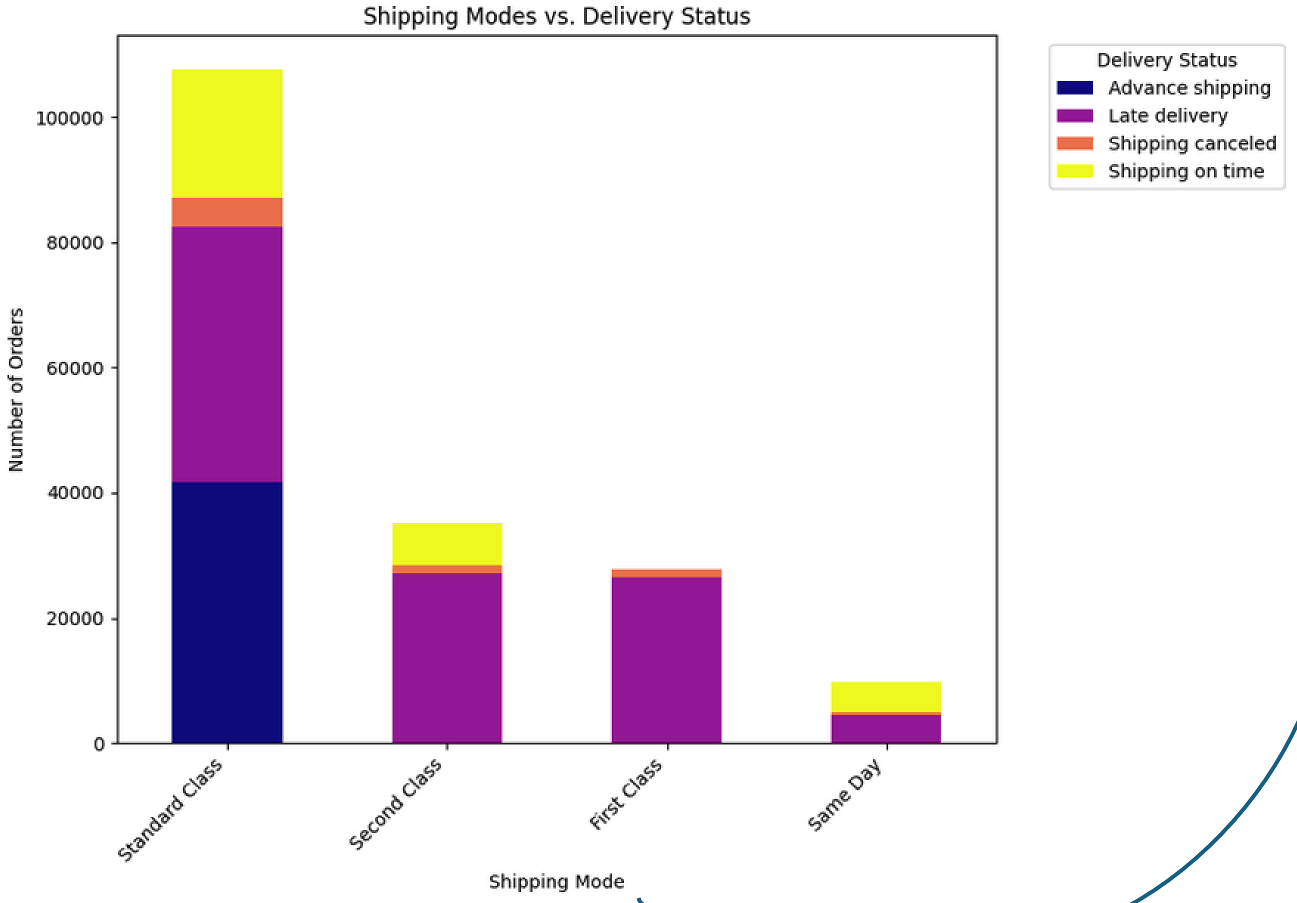

- Hoher Anteil an Verspätungen überall
- Vorzeitiger Versand (Advance Shipping) nur im Standard Class
- “Same Day” Option hat eine sichtbare Menge an pünktlichen Lieferungen- wahrscheinlich ist diese Option am teuersten?

Summary: Delivery Status distribution

	Delivery Status	Number of Orders	Percentage
0	Late delivery	98977	54.83%
1	Advance shipping	41592	23.04%
2	Shipping on time	32196	17.84%
3	Shipping canceled	7754	4.3%

Explorative Datenanalyse (EDA)
Sind die Produktkategorien mit dem höchsten Gewinn auch verspätet?

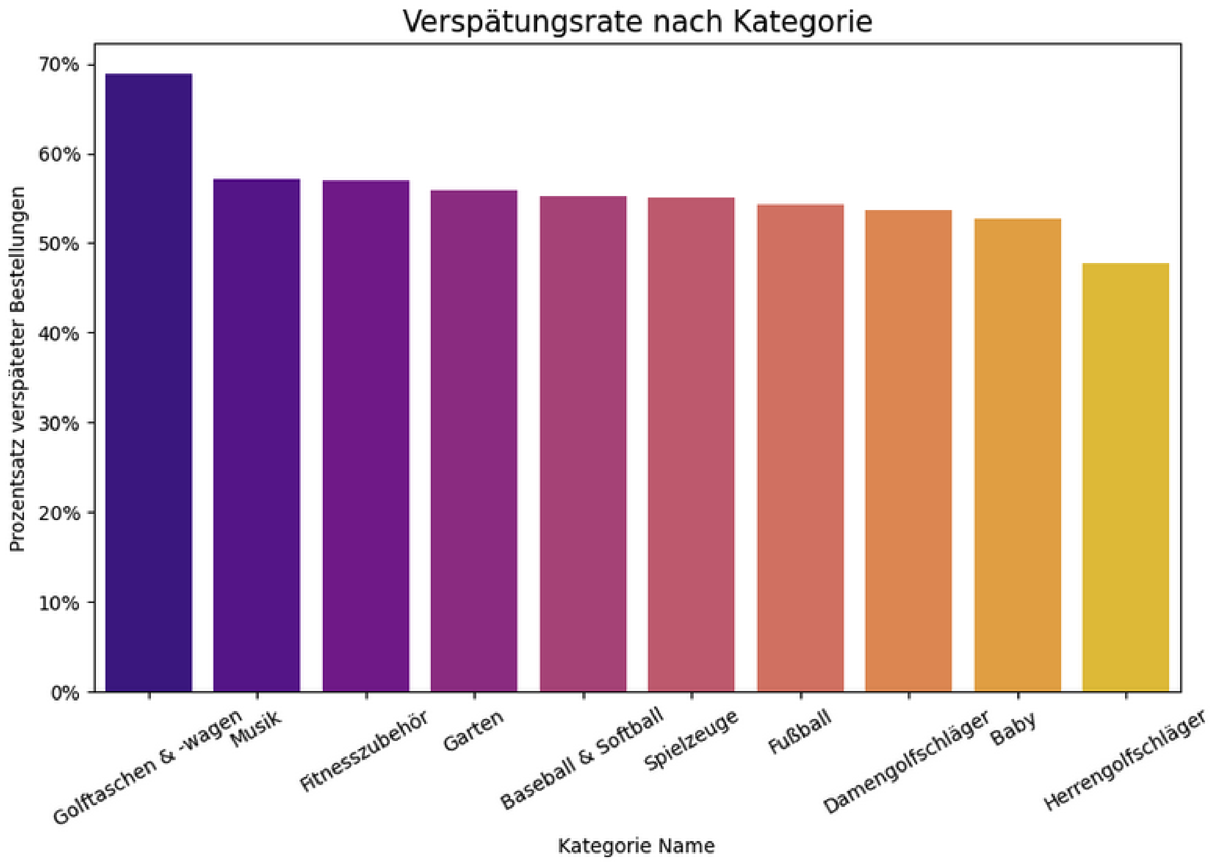


```
Top 10 Kategorien nach durchschnittlicher Gewinnspanne:
```

	Category Name DE	Order Item Profit Ratio
0	Golftaschen & -wagen	0.191475
1	Spielzeuge	0.161928
2	Fitnesszubehör	0.151230
3	Fußball	0.146522
4	Herrengolfschläger	0.145618
5	Damengolfschläger	0.145580
6	Musik	0.142650
7	Garten	0.142521
8	Baby	0.139420
9	Baseball & Softball	0.137959

Eine Analyse mit Orange

Einflussfaktoren auf Lieferverzögerungen

Lieferoption hat starken Einfluss auf die Pünktlichkeit

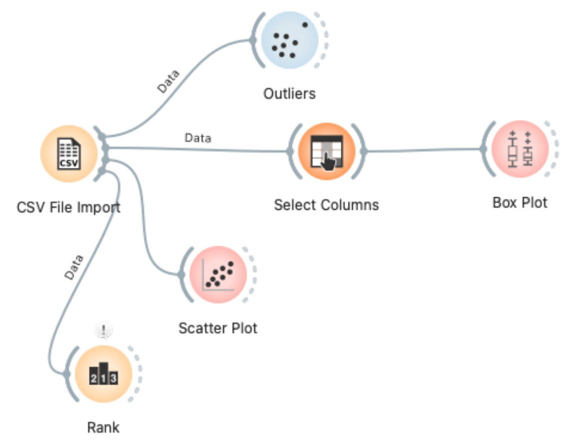

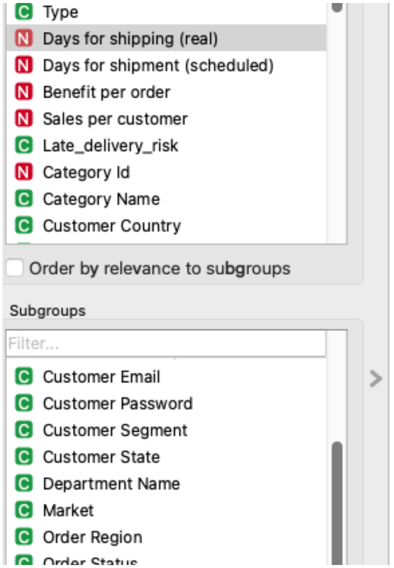

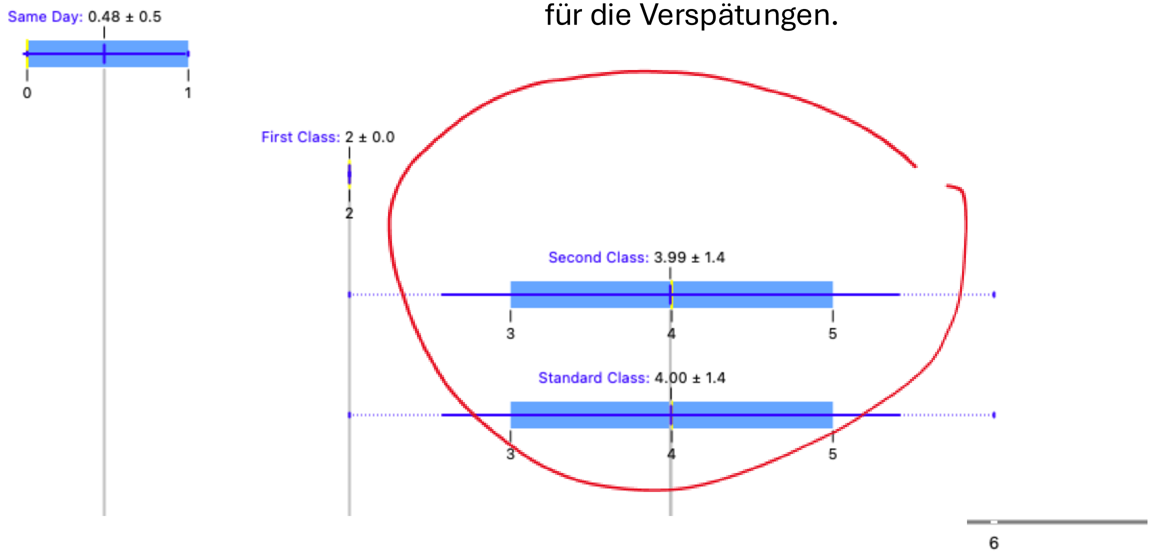

Diese zwei Lieferoptionen sind eine Ursache für die Verspätungen.

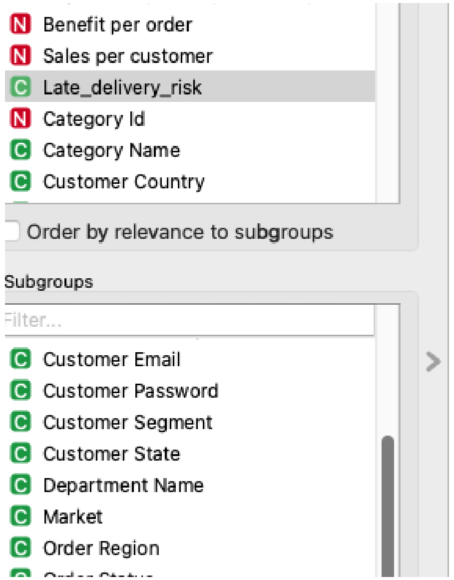

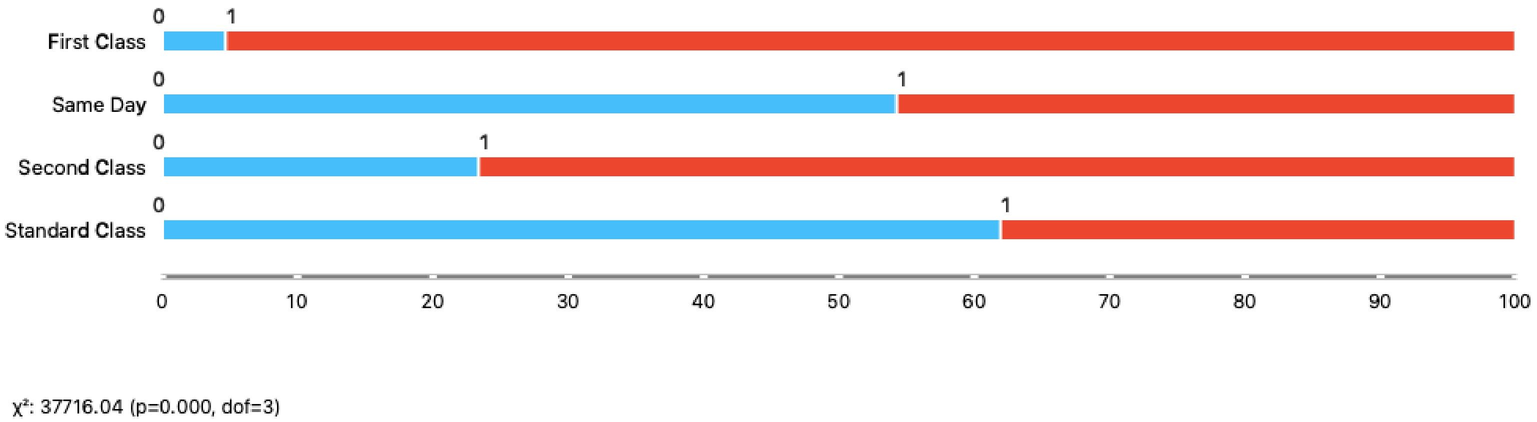

Predictive Analysis

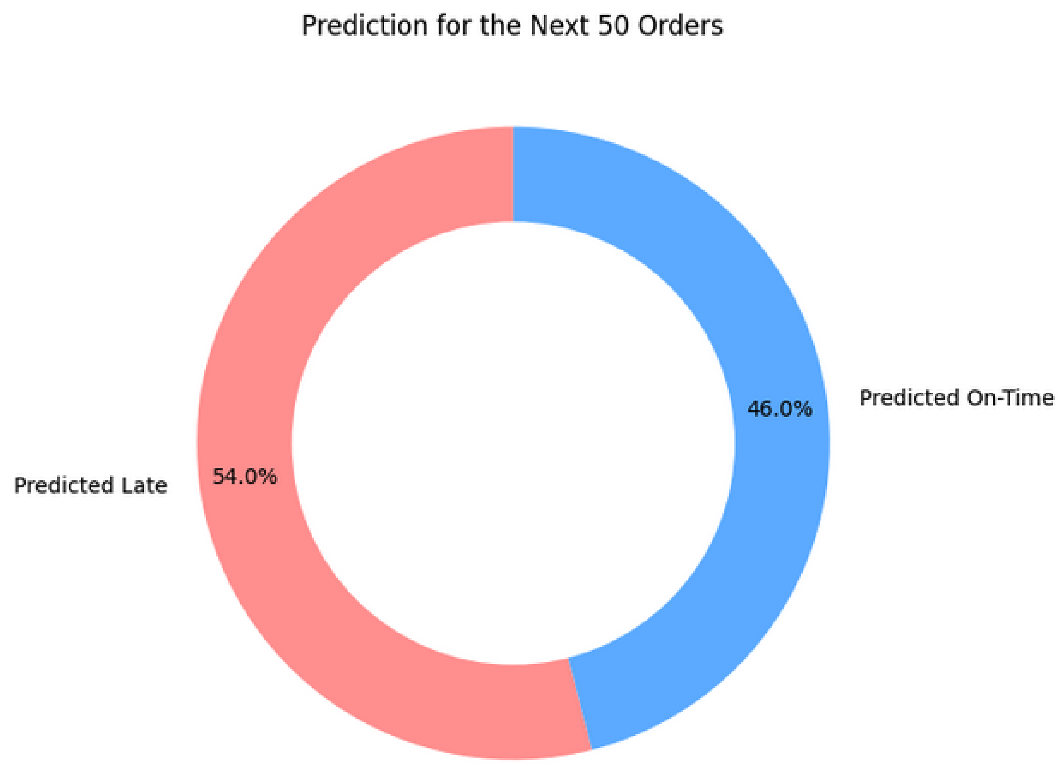


```python
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
import pandas as pd
import numpy as np

# 1. Prepare Features (X) and Target (y)
X = pd.get_dummies(df_cleaned[['Shipping Mode', 'Days for shipment (scheduled)']], drop_first=True)
y = (df_cleaned['Delivery Status'] == 'Late delivery').astype(int)

# 2. Split the data (80% for training, 20% for testing)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 3. Train the model ONLY on the training set
model_lr = LogisticRegression()
model_lr.fit(X_train, y_train)

# 4. Evaluate: How good is the model actually?
predictions = model_lr.predict(X_test)
accuracy = accuracy_score(y_test, predictions)
print(f"Model Accuracy on unseen data: {accuracy:.2%}")

# 5. Predict for the 'Next 50'
# (Using the average probability from the test set as a proxy for future orders)
probabilities = model_lr.predict_proba(X_test)[:, 1]
avg_chance = np.mean(probabilities)
print(f"Average chance of delay: {avg_chance:.2%}")
print(f"In the next 50 orders, we expect ~{round(50 * avg_chance)} delays.")
```

```
Model Accuracy on unseen data: 69.78%
Average chance of delay: 54.89%
In the next 50 orders, we expect ~27 delays.
```

```python
# Create 50 "fake" First Class orders (wir vermuten, das die Transit Zeit ist 2 Tage)
fake_first_class = pd.DataFrame({
    'Days for shipment (scheduled)': [2]*50,
    'Shipping Mode_Same Day': [0]*50,
    'Shipping Mode_Second Class': [0]*50,
    'Shipping Mode_Standard Class': [0]*50
})

# Predict for this specific scenario - Lieferung nur mit First Class Shipping Mode
risk = model_lr.predict_proba(fake_first_class)[:, 1].mean()
print(f"Risk if all 50 are First Class: {risk:.2%}")
```

```
Risk if all 50 are First Class: 92.70%
```

```python
# jetzt nur mit Standard Class (wir vermuten dass die Transit Zeit is 6 Tage)
# Create 50 "fake" Standard Class orders
fake_standard_class = pd.DataFrame({
    'Days for shipment (scheduled)': [6]*50,
    'Shipping Mode_Same Day': [0]*50,
    'Shipping Mode_Second Class': [0]*50,
    'Shipping Mode_Standard Class': [1]*50
})

# Predict for this specific scenario
risk_standard = model_lr.predict_proba(fake_standard_class)[:, 1].mean()
print(f"Risk if all 50 are Standard Class: {risk_standard:.2%}")
```

```
Risk if all 50 are Standard Class: 19.49%
```

Was ist rausgekommen? (Ergebnisse)

- Lieferverzögerungen sind ein zentrales Problem
- Lieferoptionen spielen eine entscheidende Rolle
- Ein ineffizientes Lieferkettenmanagement- die Lieferung von Produkten mit hohem Gewinn wird nicht priorisiert.
- Optimierungspotenzial in der Wahl und Steuerung der Versandarten

- Was habe ich dabei gelernt?
  - Relevante Ergebnisse und Einflussfaktoren zu finden
  - Optimierungsmöglichkeiten zu finden
  - Strukturierte Reihenfolgen zu beachten
  - Verständliche Grafiken zu nutzen

- Was muss ich noch lernen?
  - Python Vertiefung (Bibliotheken)
  - Die Zusammenhänge bei den verschiedenen Daten zu erkennen